

편채범

AI Engineer 현업 업무를 끝까지 돌아가는 AI 파이프라인으로 만드는 사람

보험금 청구·심사 도메인에서 AI Agent PoC 수행

의료정보 보안 제약 아래 설계

사람이 최종 판단하는 구조

PoC를 데모에서 끝내지 않습니다. 현업 기준으로 범위를 정하고, 실제 케이스로 재고, 안 되는 이유까지 문서로 남깁니다.

핵심 결과 3

21.5분

손해사정 34건 평균 처리 시간.
사례당 30~70시간 걸리던 업무를 2개월 안에 PoC로.

+3.68%p

남극 구름 탐지 Recall, 운영 알고리즘 CFMask 대비.
정답 라벨이 거의 없는 조건에서 단독 수행.

4분류

안 된 실험은 원인을 분류해 보고.
로컬 LLM 실패 4분류, self-training 성능 저하 원인 규명.

프로젝트 인덱스

프로젝트	역할	이 경험이 증명하는 것	면
손해사정 AI Agent 파이프라인 PoC 2026.07-08 · 비공개	2인 팀. 설계·구현·실측 전담	비공개 의료 데이터 환경에서 30~70시간 업무를 21.5분 파이프라인으로 만들어 실무자 검토 통과	3
남극 구름 탐지 Self-training 2026.03-06 · 공개	단독. 논문 검토·라벨링·모델·실험	정답이 없으면 검증 데이터를 직접 만들고, 채널 수 대신 물리적으로 맞는 feature로 기준선을 넘음	5
서해안 해기차-구름 상관 분석 2025.10-12 · 개인연구	단독. 3종 위성·재분석 자료 정합	결과가 약해도(상관 0.16) 데이터를 왜곡하지 않고 "필요조건"으로 정확하게 해석	7
위키레이싱 게임 사이트 2025.11-12 · 공개	단독. React·TS·Zustand	AI 결과를 사용자가 쓸 수 있는 화면까지 직접 만들 수 있음	7

GITHUB

github.com/dev-pyun

WEB

dev-pyun.github.io

EMAIL

hanpa2001@snu.ac.kr

소속

서울대학교 지구환경과학부 · 인공지능
복수전공

혼자 맡겨도 끝까지 갑니다. 결과는 숫자로, 실패는 원인으로 보고합니다.

배경

- 서울대학교 지구환경과학부 · 인공지능 복수전공 (2021 입학)
- 학점 3.77 / 4.3 · 자연과학대학 성적우수상 2회 (2024-1, 2024-2)
- 위성기상기후연구실 학부연구생 (2026.03-06)
- AIDAS 연구실 인턴 (2026.07-08)
- TOEIC 905 (2026.08) · OPIc IM2 (2026.09) · 공군 기상대 복무

관심 분야

현업 워크플로우 안에서 실제로 돌아가는 LLM Agent 시스템. 라벨이 부족한 도메인(원격탐사)에서의 딥러닝 모델 설계와 검증.

지원 직무

AI Engineer — LLM Agent / AX. 모델 개발 경험과 프론트엔드 구현 경험을 함께 갖춰 "결과를 쓸 수 있는 형태"까지 책임집니다.

핵심 역량

01

현업 언어를 요구사항으로

의사·손해사정사 인터뷰로 판단 기준을 뽑아, AI가 결정하면 안 되는 지점과 사람 승인 게이트를 먼저 설계합니다.

02

혼자서 end-to-end

에이전트 10개 하니스, U-Net self-training 파이프라인, 위성자료 정합 파이프라인, React/TS 프론트엔드까지 직접 구현합니다.

03

숫자로 보고, 실패는 분류

34건 실측과 단계별 타이밍 계측. 실패 원인 4분류. 기대와 다른 실험 결과는 숨기지 않고 원인을 밝혀 다음 설계 조건으로 남깁니다.

기술 스택

AI · 데이터

Python

PyTorch

NumPy / pandas / xarray

rasterio · GeoTIFF · Zarr

Agent · 검증

Claude Code 기반 Agent 하니스

JSON Schema

pytest

OpenRouter (오픈웨이트 모델 실험)

웹 · 협업

TypeScript

React

Next.js

Zustand

Git / GitHub

함께 일하면 이렇습니다

착수 전에 현업이 실제로 쓰는 판단 기준을 확인하고, AI가 결정하면 안 되는 지점을 먼저 정합니다.

전체 흐름을 먼저 돌린 뒤 계측으로 병목을 찾습니다. 추측으로 고치지 않습니다.

안 된 실험은 원인을 분류해 보고합니다. 나쁜 소식을 늦게 전하지 않습니다.

손해사정 AI Agent 파이프라인 PoC

보험금 청구·심사 도메인

비공개 · 세부 구현은 일반화하여 기술

2인 팀 · 설계·구현·실측 전담

Claude Code 기반 하니스 · 범용 모델 Opus 5

2개월 안에, 비공개 의료 데이터 환경에서, 30~70시간짜리 업무를 21.5분 파이프라인으로 만들어 실무자 검토를 통과시켰습니다.

① 문제 — 무엇이 병목이고, 어디까지 자동화할 것인가

CONTEXT

손해사정사 1명이 케이스 하나에 30~70시간을 씁니다. 진단서·판독지·진료비 명세서·약관·보험사 부지급 통지 등 수십 건의 서류를 검토하고, 약관과 대조하고, 부지급 사유를 반박해야 합니다. 법률·의료 판단 오류에는 책임이 따르고, 의료정보라 외부 서비스에 그대로 올릴 수 없습니다.

GOAL

문서 처리부터 스크리닝 리포트와 손해사정서 초안까지, 기존 OCR·LLM·검색 모델의 조합으로 자동화할 수 있는지 검증합니다. 최종 판단은 사람이 합니다.

ROLE

2인 팀에서 설계·구현·실측을 전담했습니다. 동료의 18단계 초안을 10단계로 줄인 것이 첫 의사결정이었습니다.

② 판단 — 설계에서 지킨 것 4가지

책임 경계

법률·의료 판단은 사람에게 남기고 AI는 초안까지. 의사·손해사정사 인터뷰로 출처 신뢰성, 보험사 주장 내 쟁점, 문서 검토 우선순위를 정해 범위를 확정

평가 오염 방지

평가 기준인 최종 손해사정서는 어떤 단계에서도 모델 입력에 들어가지 않도록 접근 경로를 차단. 그래서 성능 숫자를 믿을 수 있음

감사 가능성

OCR 이중 판독 불일치, 문서 분할 경계, 분류 검토, 개인정보 유출 의심 — 4곳은 사람이 승인해야 진행되고, 누가 언제 승인했는지 기록이 남음

데이터 통제

모든 에이전트는 락·원장·스키마 검증이 있는 DAO 하나를 통해서만 읽고 씀. 의료정보 접근 경로가 하나뿐

입력 → 처리 → 산출 (일반화된 흐름)

에이전트 10개 + 오케스트레이터

① 케이스 접수 파일별 검토 원장 작성 하나라도 반려되면 케이스 차단	② 문서 처리 OCR 이중 판독 → 개인정보 마스킹 → 문서 분할·분류(17종) → 청킹	③ 청구·약관 분석 핵심 필드 56개 추출 · 보장 판단 약관 조항 후보 매칭
④ 정합성·쟁점 검토 문서 간 불일치 탐지 부지급 사유 검증 · 반박 근거 생성	⑤ 스크리닝 리포트 · 초안 v1 (1차 청구) → v2 (보험사 회신 후) critic: 근거 없는 주장·금지 표현 반려	⑥ 사람 검토 손해사정사가 최종 판단 정답지는 모델 입력에서 격리

사람 게이트 4곳: OCR 판독 불일치 · 분할 경계 · 분류 검토 · PII 유출 의심 | 모든 읽기·쓰기는 DAO 단일 경로 · JSON Schema I/O 계약 · 단계별 타이밍 계측

그림 1. 파이프라인 구조(일반화). 에이전트 10개(문서 처리, 약관 추출, 청구 분석, 정합성 검사, 부지급 사유 검증, 스크리닝 리포트, 초안 작성, critic 등)와 오케스트레이터로 구성. 케이스·프롬프트·규칙 세부는 비공개.

속도를 올린 방법은 모델 교체가 아니라 계측이었습니다

③ 구현과 검증

EXECUTION

- 전체 흐름이 끝까지 실행되도록 먼저 구축한 뒤, 각 에이전트의 중간 산출물을 단계별로 검토. 동일 자료의 중복 참조와 최종 결과에 기여하지 않는 긴 추론이 병목임을 확인
- 의료문서 17종, 추출 필드 56개로 세분화. 우선순위 문서에서 값이 확보되면 탐색을 중단하고, 중간 결과를 후속 단계가 재사용
- 문서별 OCR과 약관 처리·거절 사유 추출을 병렬화
- OCR은 두 경로로 판독해 교차검증. 개인정보는 LLM이 위치를 찾고 결정적 규칙으로 치환, 유출 감지 시 즉시 중단

VALIDATION

- 실제 종결 케이스 34건 실측. 단계별 타이밍 계측을 파이프라인에 내장해 "어디서 시간이 가는지"를 기록으로 확인
- 출력은 손해사정사가 검토 — 출처 제시, 보험사 주장 내 쟁점 파악 등 핵심 품질 유지 여부
- 단위 테스트(pytest)는 실제 케이스가 아닌 임시 경로에서만 실행

④ 결과

처리 시간

기준선 (수작업)		30~70시간
초기 파이프라인		약 50분
최종 PoC (34건 평균)		21.5분

막대는 초기 파이프라인 대비 상대 비율(기준선은 축척 밖). 초기 대비 57% 단축. 수작업 기준선과는 단위가 달라 배수로 표현하지 않았습니다.

로컬(오픈웨이트) 모델 전환 실험

조건	케이스 2건 × 오픈웨이트 모델 8종 (OpenRouter)
완주율	16회 중 5회 · 두 케이스 모두 완주한 모델은 Qwen3-VL 32B 1종
실패 원인	tool call 미반환 · 출력 절단 · JSON 위반 ·
4분류	OCR 환각

보안상 클라우드 모델을 못 쓰는 고객을 가정한 실험. 이 표가 다음 의사결정의 근거입니다 — Qwen 계열을 우선 후보로, EXAONE 등 한국어 특화 모델을 같은 조건에서 비교하는 과제를 남겼습니다.

LEARNING

속도는 모델 교체보다 어떤 단계가 결과에 기여하지 않는지를 기록으로 찾는 데서 나왔습니다. 계측 없이 추측으로 고치지 않는 것이 원칙이 됐습니다.

범용 모델로 검증한 설계가 로컬 모델에서 깨졌습니다. 다음 프로젝트에서는 **배포 모델의 제약(도구 호출 형식, 출력 길이)**을 설계 첫날 **확인**합니다.

"보험사 주장 허점 발견" 같은 정성
성과는 **실무자 검토를 거쳐야만** 성과로
인정했습니다.

공개 범위 안내

가명처리된 의료·보험 케이스를 다루는 연구실 프로젝트라 코드·프롬프트·케이스는 공개하지 않습니다. 위 내용은 문제 구조, 시스템 흐름, 본인의 판단과 검증 방식으로 한정해 기술했습니다.

남극 구름 탐지 Self-training

공개

단독 수행 (연구실 선배 자문)

Landsat 8 OLI · PyTorch

github.com/dev-pyun/CMA-project

정답 라벨이 거의 없는 문제에서, 채널을 늘리는 대신 물리적으로 맞는 4개를 골라 운영 알고리즘 (CFMask)을 넘었습니다. 기대했던 방법이 안 됐을 때는 원인을 밝혀 다음 설계 조건으로 남겼습니다.

① 문제

CONTEXT

위성 영상에서 구름 마스크의 품질은 후속 분석의 품질을 결정합니다. Landsat의 규칙 기반 마스크 CFMask는 눈·얼음 지역에서 유독 정확도가 낮고(Foga et al., 2017), 남극은 픽셀 단위 정답 라벨이 거의 없습니다 — 기존 검증 데이터셋에서 극지 scene은 48개 중 2~4개뿐입니다.

GOAL · ROLE

CFMask의 noisy label만으로 남극 구름 마스크를 개선할 수 있는지, 어떤 스펙트럼 feature가 유효한지, 정답이 부족할 때 self-training이 실제로 도움이 되는지 검증합니다.

단독 수행. 논문 23편 검토부터 데이터셋 구성, 검증용 픽셀 라벨링, U-Net·self-training 구현, 실험 설계와 발표까지 4개월 안에 혼자 완주했습니다.

② 판단 — 방법·데이터·지표 선택

Self-training 채택

정답 부족 + noisy label 활용 가능 조건에 맞는 방법 (Nambiar et al., 2022 참고)

검증 데이터는 직접 만들

Weddell Sea 37 scene 중 8 scene을 오픈소스 도구 napari로 픽셀 단위 라벨링. 불명확한 영역은 라벨링하지 않고, 수동 라벨 비율 30% 이상 패치만 평가에 사용

밴드 선택은 PCA로

Band 6·7·9에 영향받는 주성분이 구름을 잘 구분하는 것을 확인해 SWIR·Cirrus 중심 4채널 구성(EXP 3)을 추가

평가 지표는 mIoU

cloud/no-cloud 불균형을 고려해 accuracy 대신 사용. 검증셋은 gradient 업데이트에 쓰지 않고 모델 선택에만 사용

EXECUTION

- 2020년 1~4월, 10~12월 Weddell Sea 37 scene → 258×258 패치. train 29 / validation 8, 인접 위치가 양쪽에 섞이지 않도록 scene 단위 분할
- U-Net(Conv-BN-Dropout 인코더, skip connection 디코더)
- 학습 데이터를 A-D 25%씩 나눠 stage마다 범위 확장. 이전 stage best 모델의 confidence ≥ 0.65 픽셀만 pseudo label로 채택
- 입력 조합 5종 실험 (Band 2-7+NDSI / +NDWI / +PC1-3 / Band 2-7,9+NDSI / Band 6,7,9+NDSI)

Stage 0	Stage 1	Stage 2	Stage 3
A (CFMask label) 1.9M 픽셀	A + B (Stage 0 pseudo) 7.8M 픽셀	A + B, C (Stage 1 pseudo) 17.5M 픽셀	A + B, C, D (Stage 2 pseudo) 31.1M 픽셀

각 stage의 best 모델은 수동 라벨 검증셋 mIoU로 선택 · confidence < 0.65 픽셀은 ignore label · 검증셋은 gradient 업데이트에 미사용

그림 2. Stage별 self-training 절차. 학습 데이터를 4개 구간으로 나눠 이전 stage 모델이 만든 pseudo label로 학습 범위를 넓혀 간다.

4채널 모델만 CFMask를 넘었고, Stage 0가 가장 좋았습니다


③ 결과 — 수동 라벨 검증셋 8 scene, cloud 클래스 기준

모델 (입력 채널)	OA	Prec.	Recall	F1
CFMask (기준선)	0.862	0.942	0.835	0.885
EXP 1 · B2-7, NDSI, NDWI	0.817	0.907	0.796	0.848
EXP 2 · B2-7, 9, NDSI	0.839	0.909	0.832	0.869
EXP 3 · B6, 7, 9, NDSI	0.884	0.938	0.872	0.904

EXP 3: mIoU 0.778, CFMask 대비 **Recall +3.68%p · F1 +1.83%p · OA +1.91%p**. 5개 입력 조합 중 CFMask보다 나은 것은 EXP 3 하나뿐이었습니다.


입력 채널	Best stage	OA	mIoU
B2-7, NDSI	0	53.6%	0.349
B2-7, NDSI, NDWI	3	81.7%	0.682
B2-7, NDSI, PC1-3	0	77.2%	0.474
B6, 7, 9, NDSI	0	88.4%	0.778
B2-7, 9, NDSI	1	83.9%	0.712

CFMask는 같은 검증셋에서 OA 86.2%. 5개 중 4개 실험에서 Stage 0 또는 1이 best — 숨기지 않고 전부 표로 정리했습니다.



FALSE COLOR CFMASK EXP 3 (본 연구)

그림 3. 맑은 하늘(SK) scene에서 CFMask가 과대탐지한 영역(붉은 원)을 EXP 3이 줄인 사례. LC08_L1GT_160109_20201126.



FALSE COLOR EXP 3 · STAGE 0 EXP 3 · STAGE 3

그림 4. 같은 scene에서 Stage 3이 Stage 0보다 구름을 놓치는 사례. pseudo label 누적 후 성능이 떨어진 근거.

기대와 달랐던 결과를 어떻게 다뤘는가

- **무엇이 달랐나** — 설계 의도는 Stage 3에서 최고 성능이 나오는 것이었지만, 5개 중 4개 실험에서 Stage 0 또는 1이 best였고 이후 stage에서 mIoU가 떨어졌습니다.
- **어떻게 확인했나** — 좋은 결과만 고르지 않고 5개 실험 전부의 stage별 mIoU를 표로 정리하고, 같은 scene의 Stage 0 / Stage 3 예측을 나란히 놓아(그림 4) 성능 저하가 실제 탐지 누락으로 나타나는지 확인했습니다.
- **원인을 어떻게 판단했나** — pseudo label 오류가 stage마다 누적되는 **확증편향(confirmation bias)**으로 판단했고, 격자무늬 artifact는 패치 경계 예측이 stitching에서 해소되지 않은 것으로 추정했습니다.
- **어떻게 남겼나** — 원인과 대응(confidence 임계값 상향, supervised baseline 우선)을 발표에 한계와 다음 과제로 명시했습니다.

해석 · LEARNING

SWIR(Band 6·7)과 Cirrus(Band 9)가 눈·구름 구분에 가장 유효했고, 가시·NIR 채널을 많이 넣은 조합은 오히려 성능을 떨어뜨렸습니다. 채널 수보다 **물리적으로 유효한 feature 선택**이 중요합니다.

이 실험에서 배운 것은 방법론보다 학습 데이터의 품질이 먼저라는 점입니다. 다음 실험에서는 신뢰할 수 있는 정답 기반의 supervised baseline을 먼저 확보한 뒤 semi-supervised를 보조로 쓸 계획이며, confidence 임계값 상향(0.95), SCSI 등 feature 추가, 다른 극지 영역·계절 검증을 다음 과제로 정리했습니다.

LIMITS 독립 test set 없이 수동 검증셋으로만 평가 · Weddell Sea, 2020년에 한정 · 3-class(cloud/shadow/snow) 확장은 라벨만 준비

보조 프로젝트

서해안 해기차-구름 상관 분석

2025.10-12 · 개인연구 (A+)

결과가 약해도 데이터를 왜곡하지 않고, 왜 약한지를 설명해 A+를 받았습니다.

문제

겨울철 서해안 강설의 지표로 쓰이는 해기차(SST - 상층 기온)가 실제 구름 발생을 얼마나 설명하는지 위성 관측으로 정량화.

판단

정지궤도 SST 대신 구름 오염이 적은 야간 GHRSSST L4 사용 · GK-2A 운량은 품질 플래그(CA_DQF, CT_DQF)로 유효 픽셀만 집계 · 하층운 변수(CLL)는 결측이 많아 제외하고 한계로 명시.

실행

GK-2A CLA · GHRSSST · ERA5(850/700hPa)를 0.25° 격자로 정합, 2021-2025 겨울 1,083시간 Spearman 상관 분석.

결과

전체 상관 0.16 / 0.04로 약했지만 일별로는 $-0.6 \sim 0.8$, $|r| > 0.4$ 인 날 26.7% / 17.6%. 운량이 0과 1에 몰린 이봉 분포를 근거로 해기차는 구름 발생의 필요조건이지 충분조건은 아니므로 결론.

2024.11 수도권 극한강설 원인 분석

2025.09-12 · 3인 팀 · 영어 발표

팀이 답하지 못한 질문 3개를 맡아 5팀 중 1위 발표를 만들었습니다.

문제

해기차 기반 서해안 강설 모델로는 수도권에 집중·지속된 기록적 11월 폭설을 설명할 수 없었음.

본인 역할

중간발표에서 답하지 못한 3개 질문의 종관 분석 — 남중국 고기압의 이상 형태(상층 한기 침강), 저리저기압의 경압 → 순압 전이로 인한 정체와 제트 블로킹(AO 음의 지수), 28일 강설 종료 원인 3가지. 분석 틀(발생·집중·지속·종료)과 영어 대본 조율.

결과

5개 팀 중 1위. 담당 교수로부터 "대학원생 수준"이라는 평가.




그림 5. ΔT vs cloud fraction 산점도 (850/700hPa)




그림 6. 일별 상관계수 분포



그림 7. 2024.11.26 18UTC 위성영상 — 기압골 영향의 곡률을 보이는 구름대

위키레이싱 게임 사이트

2025.11-12 · 네이버 커넥트재단 연계 수업 (A+)

AI 결과를 사용자가 쓸 수 있는 화면까지 만들 수 있습니다. 링크 클릭만으로 목표 문서에 도달하는 게임. 되돌리기·분기가 잦은 탐색 경로를 branches / pathRefs 구조로 설계해 Git 그래프처럼 시각화하고, 리더보드 중복 기록을 방지. React · TypeScript · Zustand. github.com/dev-pyun/Wiki_Racing-dev-pyun

그 외

예비창업패키지 '점주' (2026.01-02, 팀) — 구조·인증·상태관리 기획 주도, 구현은 PR 기반 공동 작업. 사업계획서·MVP 제출, 최종 미선정. 비공개 저장소.

영화 추천 챌린지 (데이터마이닝 수업) — 협업 필터링 AUC 0.952에서 TruncatedSVD(rank 150) + 6 seed 앙상블로 0.996.

CONTACT

github.com/dev-pyun
dev-pyun.github.io
hanpa2001@snu.ac.kr



GITHUB



WEB